NLP

Preprocesamiento de texto

Msc. Rodrigo Cardenas Szigety
rodrigo.cardenas.sz@gmail.com

Esp. Ing. Hernán Contigiani
hernan4790@gmail.com

Programa de la materia

Clase 1: Introducción a NLP, Vectorización de documentos.
Clase 2: Preprocesamiento de texto, librerías de NLP y Rule-Based Bots.
Clase 3: Word Embeddings, CBOW y SkipGRAM, representación de oraciones.
Clase 4: Redes recurrentes (RNN), problemas de secuencia y estimación de próxima palabra.
Clase 5: Redes LSTM, análisis de sentimientos.
Clase 6: Modelos Seq2Seq, traductores y bots conversacionales.
Clase 7: Celdas con Attention. Transformers, BERT & ELMo, fine tuning.
Clase 8: Cierre del curso, NLP hoy y futuro, deploy.

*Unidades con desafíos a presentar al finalizar el curso.
*Último desafío y cierre del contenido práctico del curso.

Preprocesamiento de texto

LINK GLOSARIO

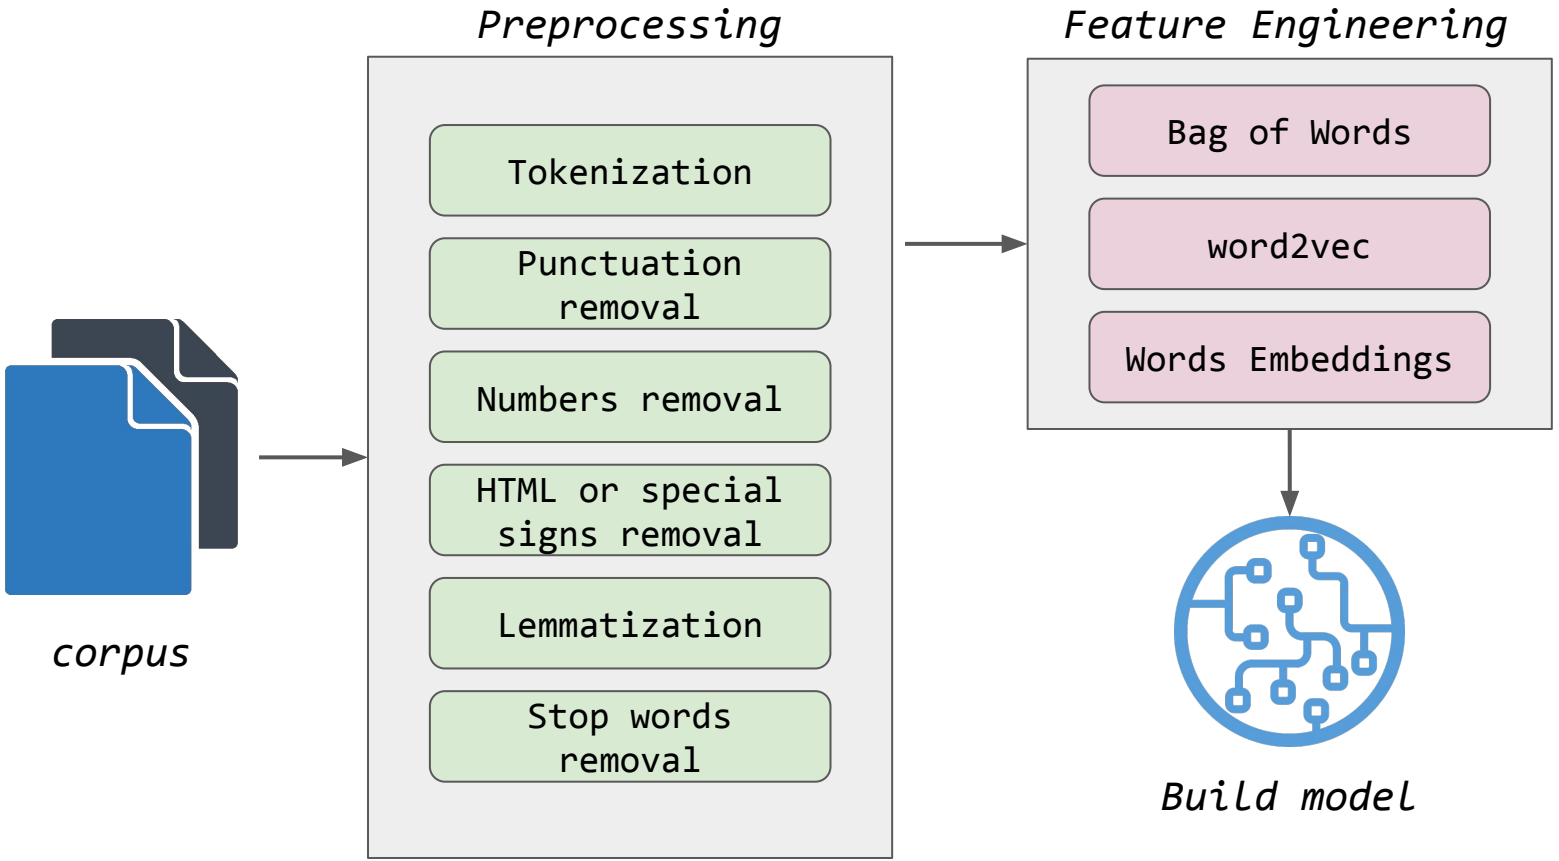

Tokenizar

"Proceso en el cual una sentencia o documento es dividida en palabras o términos individuales. Los símbolos son dejados aparte para luego tratarlos"

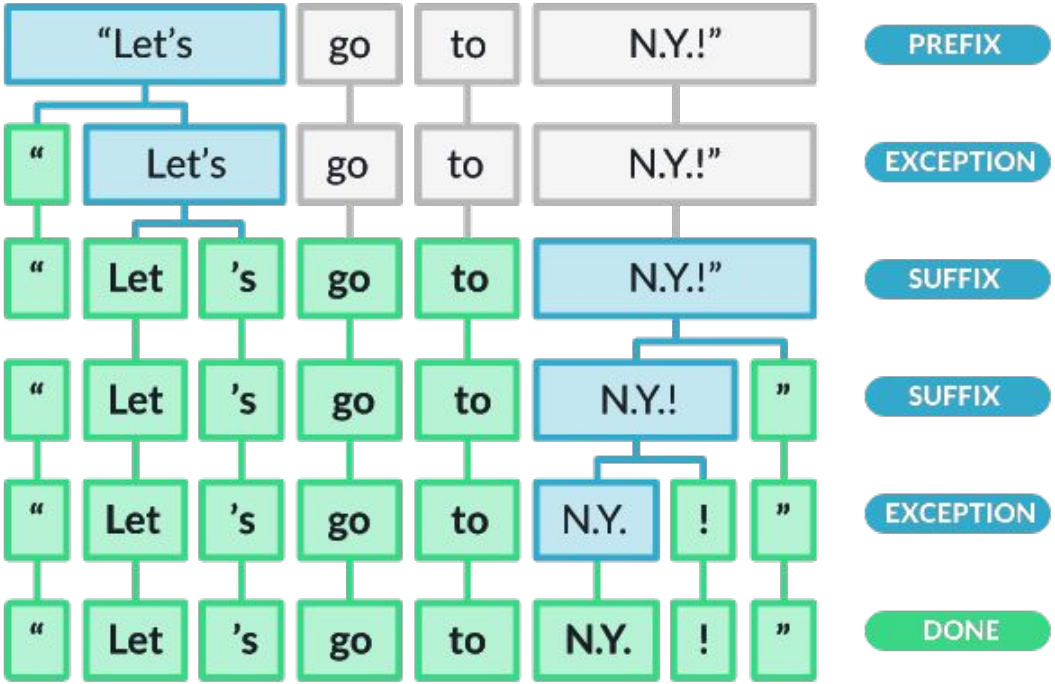

Derivado (steeming)

"Devolverá el tallo de una palabra, que no necesita ser idéntica a la raíz morfológica de la palabra"

Elimina los prefijos

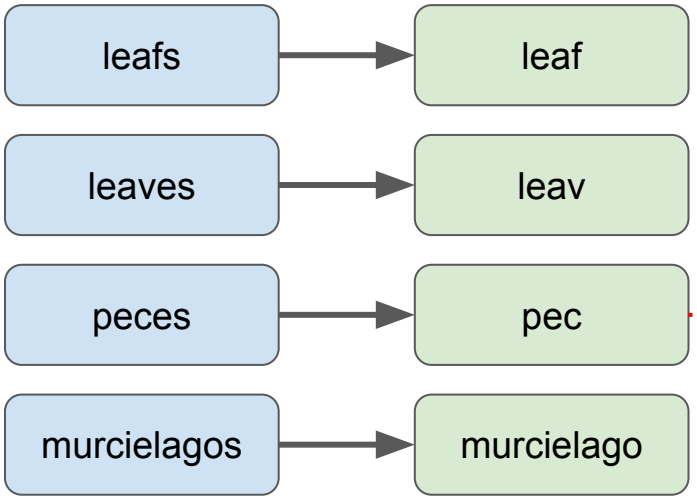

plural irregular

especimen, especímenes
régimen, regímenes

Lematización (lemmatization)

"Devolverá la forma diccionario de una palabra, su raíz"

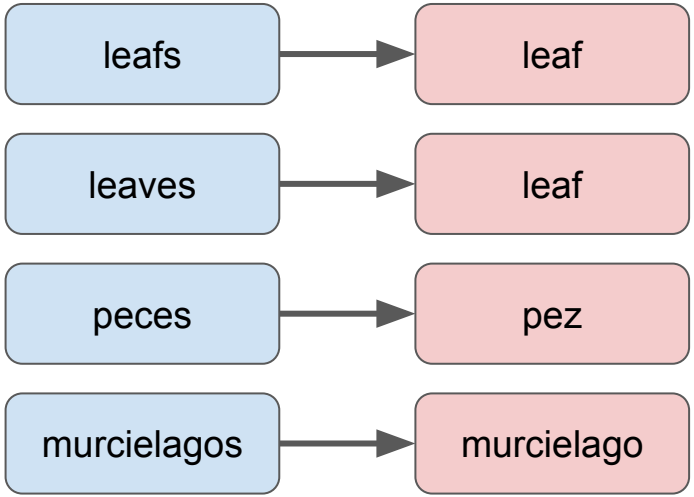

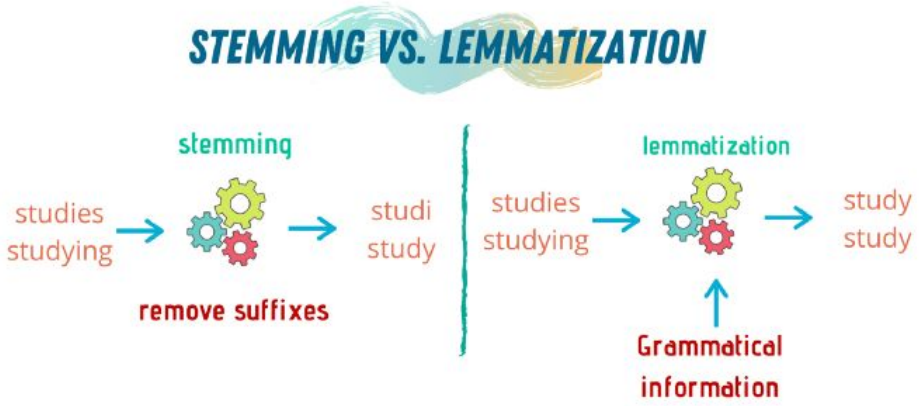

Parts-of-speech (POS) - Tagging

*"POS es el proceso de identificar cada término en la oración, tageandolos como **sustantivo (noun), verbo (verb), adjetivo (adj)**, etc"*

Stop words

"Palabras que no aportan valor al significado de una oración ya que son muy frecuentes o comunes en el lenguaje"

artículos | pronombres | preposición

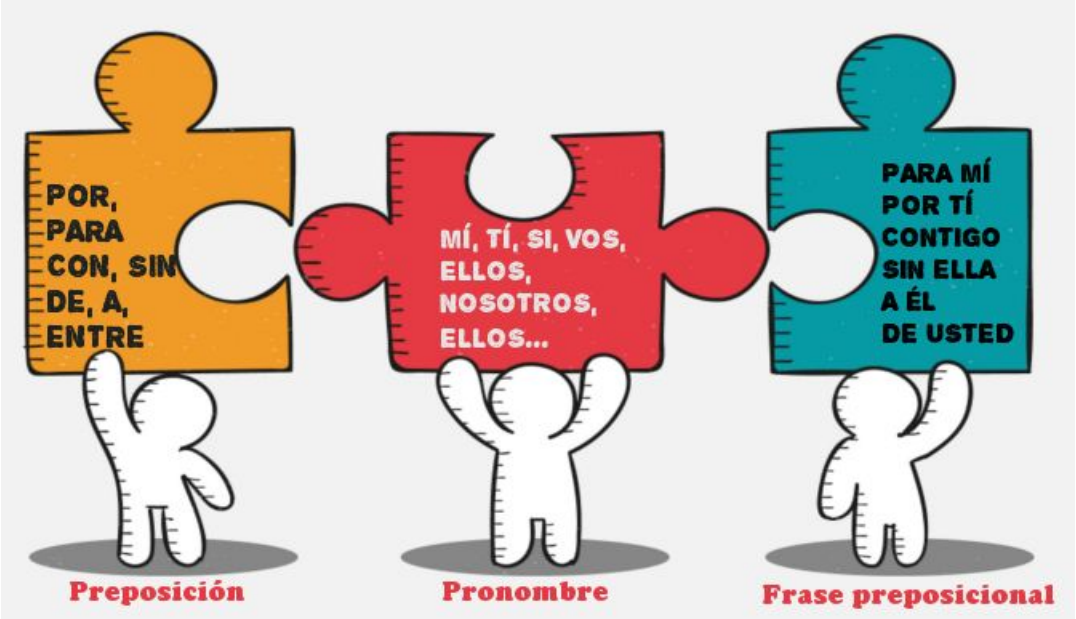

Stop words

Analizar un texto relacionado con calentamiento global (global climate)

Texto con Stop Words

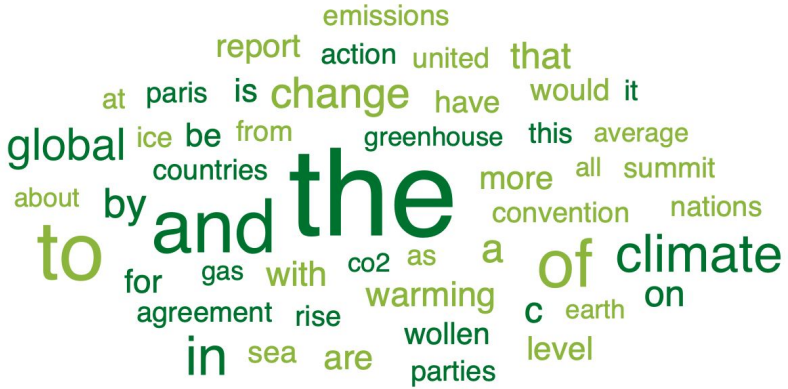

Texto sin Stop Words

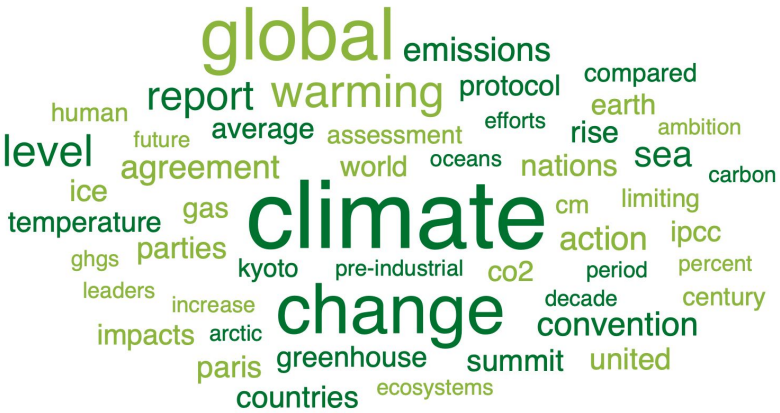

Librerías de NLP

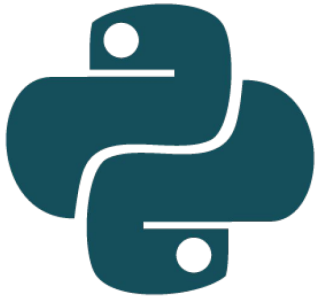

NLTK

- Gran comunidad detras
- No soporta GPU
- Más optimizada
- Más lenta en gran volúmenes de datos o operaciones

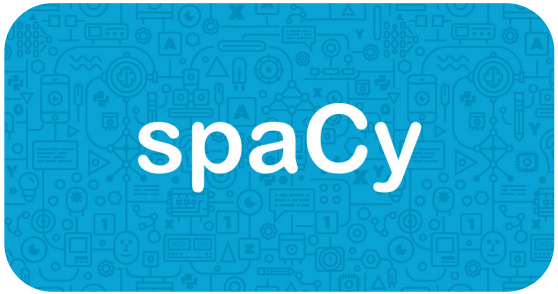

- Más moderna e implementa los últimos features
- Soporta GPU
- Menos optimizada
- Más rápida en gran volúmenes de datos o operaciones

NLTK

LINK PÁGINA

"Librería por excelencia de procesamiento de lenguaje natural para Python"
Inicios 2009

Implementa una tool/algoritmo para cada etapa de preprocesamiento de NLP

spaCy

LINK PÁGINA

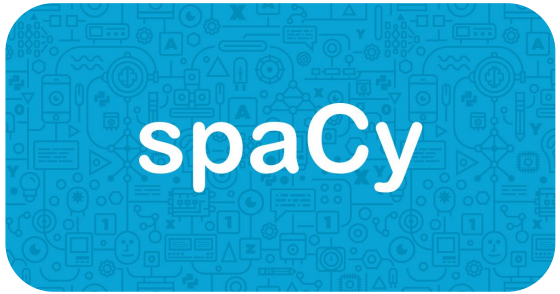

Inicios 2015

- Support for **64+ languages**
- **63 trained pipelines** for 19 languages
- Multi-task learning with pretrained **transformers** like BERT
- Pretrained **word vectors**
- State-of-the-art speed
- Support for custom models in **PyTorch**, **TensorFlow** and other frameworks

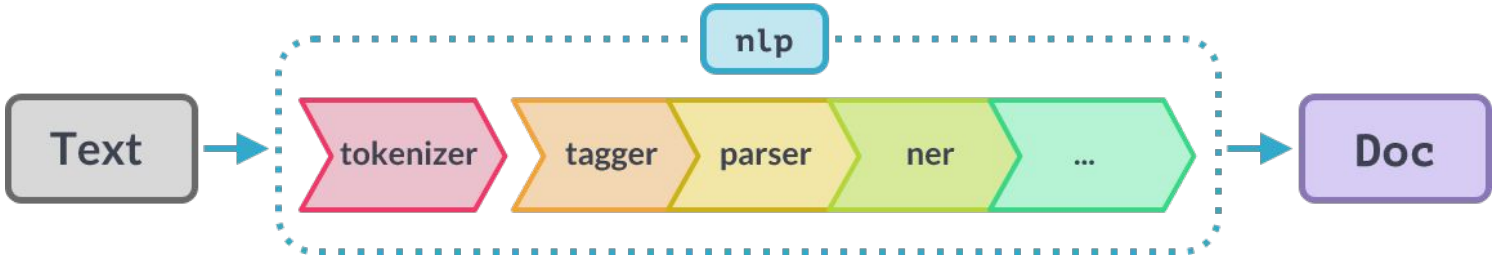

spaCy

LINK PÁGINA

```python
import spacy

nlp = spacy.load("en_core_web_sm")
doc = nlp("Apple is looking at buying U.K. startup for $1 billion")

for token in doc:
    print(token.text, token.lemma_, token.pos_, token.tag_, token.dep_,
            token.shape_, token.is_alpha, token.is_stop)
```

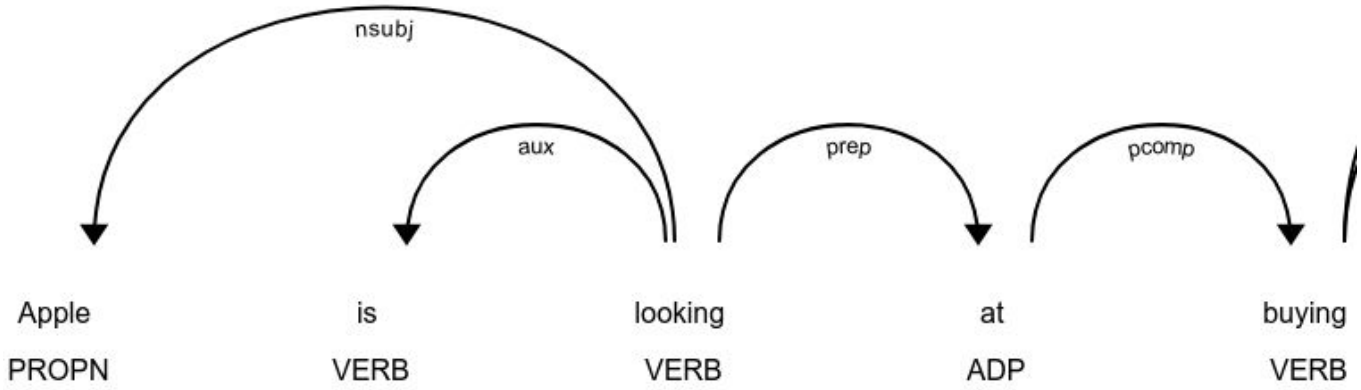

Un resumen de todo lo visto

POS TAG DEP

TEXT	LEMMA	POS	TAG	DEP	SHAPE	ALPHA	STOP
Apple	apple	PROPN	NNP	nsubj	Xxxxx	True	False
is	be	AUX	VBZ	aux	xx	True	True
looking	look	VERB	VBG	ROOT	xxxx	True	False
at	at	ADP	IN	prep	xx	True	True
buying	buy	VERB	VBG	pcomp	xxxx	True	False
U.K.	u.k.	PROPN	NNP	compound	X.X.	False	False
startup	startup	NOUN	NN	dobj	xxxx	True	False
for	for	ADP	IN	prep	xxx	True	True
$	$	SYM	$	quantmod	$	False	False
1	1	NUM	CD	compound	d	False	False
billion	billion	NUM	CD	pobj	xxxx	True	False

Preprocesamiento

Link al Colab

LINK

BOTs lingüístico

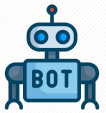

Son limitados a una tarea específica

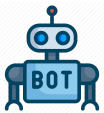

Fácil y "barato" de entrenar

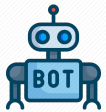

Ideal para chats de pedidos

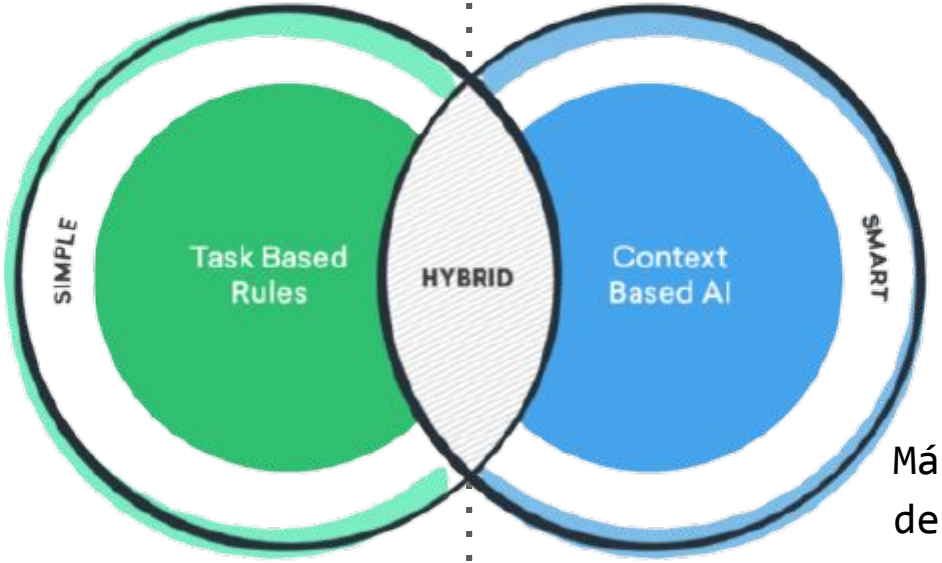

Interactúan casi como un humano

Más difíciles de entrenar, requieren más datos y cómputo

Ideal para asistentes virtuales

Rule-Based BOT

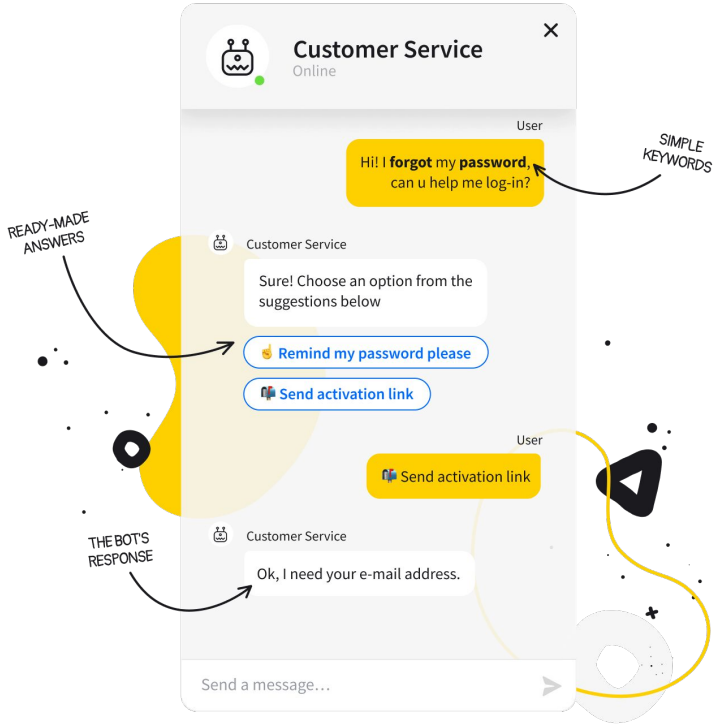

Nuestro bot será entrenado con <TAGS> (ej: saludo)

Cada <TAG> será representado por un patrón de posibles preguntas <patterns> (X)

Cada <TAG> tendrá uno o varias posibles respuestas <classes> (y)

Rule-Based BOT con DNN

Link al Colab

LINK

Rule-Based BOT con TF-IDF

Link al Colab

LINK

Desafio

Tomar un ejemplo de los bots utilizados

Construir el propio

¡Muchas gracias!