

## ***NLP***

# Vectorización de documentos

Msc. Rodrigo Cardenas Szigety  
rodrigo.cardenas.sz@gmail.com

Esp. Ing. Hernán Contigiani  
hernan4790@gmail.com

# Programa de la materia



**Clase 1:** Introducción a NLP, Vectorización de documentos.

**Clase 2:** Preprocesamiento de texto, librerías de NLP y Rule-Based Bots.

**Clase 3:** Word Embeddings, CBOW y SkipGRAM, representación de oraciones.

**Clase 4:** Redes recurrentes (RNN), problemas de secuencia y estimación de próxima palabra.

**Clase 5:** Redes LSTM, análisis de sentimientos.

**Clase 6:** Modelos Seq2Seq, traductores y bots conversacionales.


**Clase 7:** Celdas con Attention. Transformers, BERT & ELMo, fine tuning.

**Clase 8:** Cierre del curso, NLP hoy y futuro, deploy.

\*Unidades con desafíos a presentar al finalizar el curso.

\*Último desafío y cierre del contenido práctico del curso.

# Link Github de la materia




[https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento\\_lenguaje\\_natural](https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural)



# ¿Cómo me acercaran sus soluciones?



Su repositorio



(mensaje directo)

Nos envían el link (por DM)  
del repositorio notificando  
que ya puedo observar su  
trabajo N°XX



Colab link



Jupyter  
notebook

# ¿Cómo se evaluarán los desafíos?



	Clases								Recu
	1~2	2~3	3~4	4~5	5~6	6~7	7~8	8	
Desafío 1	9-10	9-10	8-9	8-9	7-8	7-8	6-7	6-7	4-6
Desafío 2		9-10	9-10	8-9	8-9	7-8	7-8	6-7	4-6
Desafío 3			9-10	9-10	8-9	7-8	7-8	6-7	4-6
Desafío 4				9-10	9-10	8-9	7-8	6-7	4-6
Desafío 5					9-10	9-10	8-9	7-8	4-6
Desafío 6						9-10	8-9	7-8	4-6
Desafío 7							9-10	8-9	4-6

\*La instancia de recuperación comienza 1 semana después de haberse dictado la última clase. La instancia de recuperación tiene una duración de una semana límite para **terminar de entregar los desafíos**

# ¿Qué es NLP?



El procesamiento de lenguaje natural (PLN o NLP) es un campo de la

*Inteligencia artificial + Lingüística*



*Traductor*



*Detector fraude*



*Detector de SPAM*



*Pred. dolencias*



*Corrector*



*Respuesta Autom.*




*Análisis de sent.*



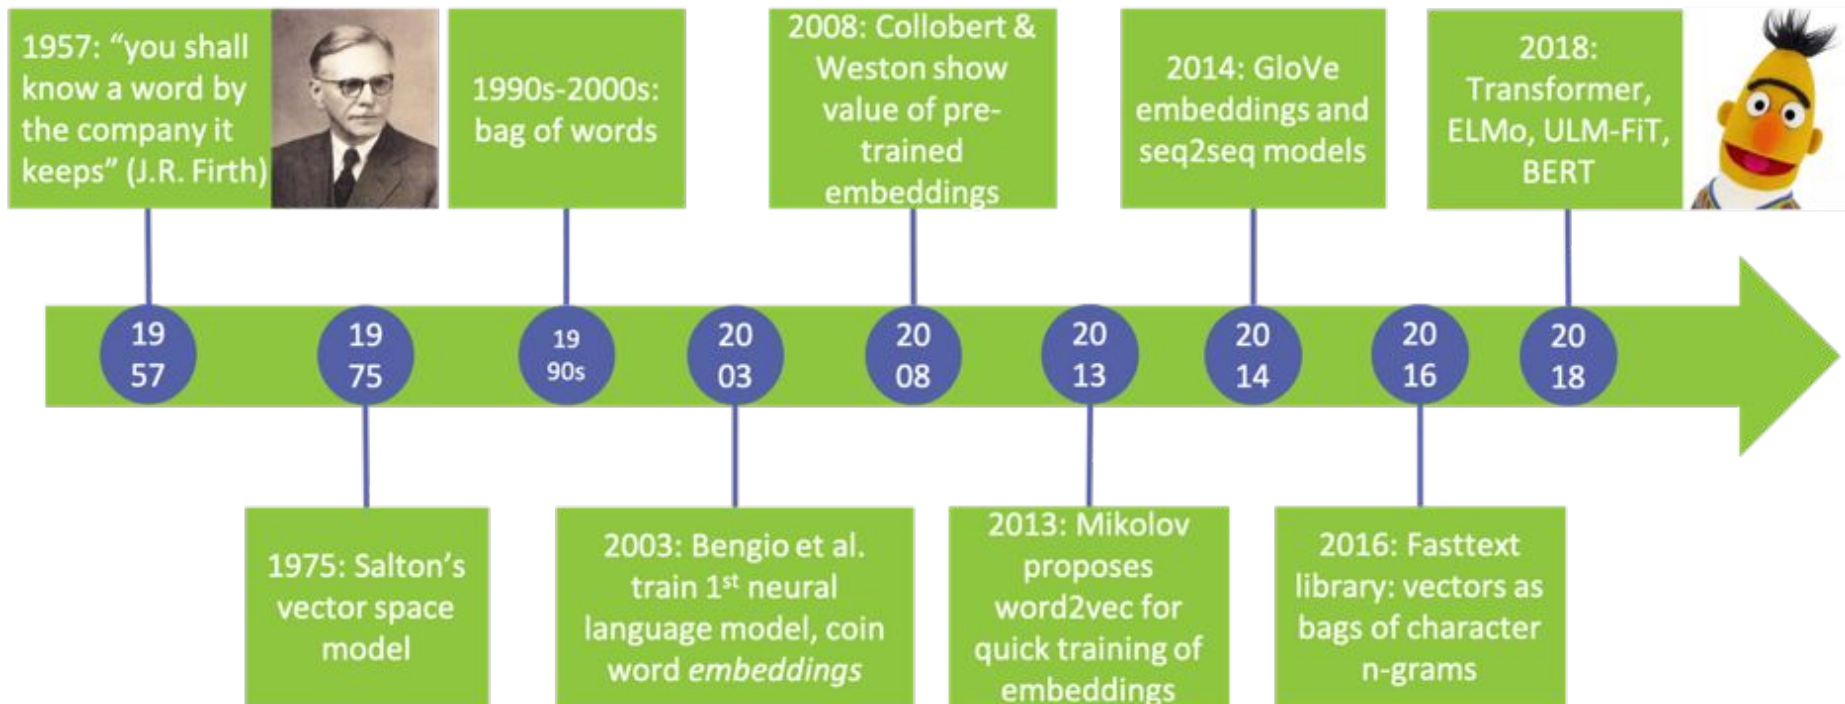
*Asistente por voz*

# Campos de aplicación del data science






# Timeline



# Test de turing "1950"



¿Puede una máquina  
hablar como si fuera  
un humano?



Blade runner  
"Test emocional"

En 2014 una computadora  
logra superar parcialmente  
este ensayo

# Eliza (1964) - Primer bot NLP



Welcome to


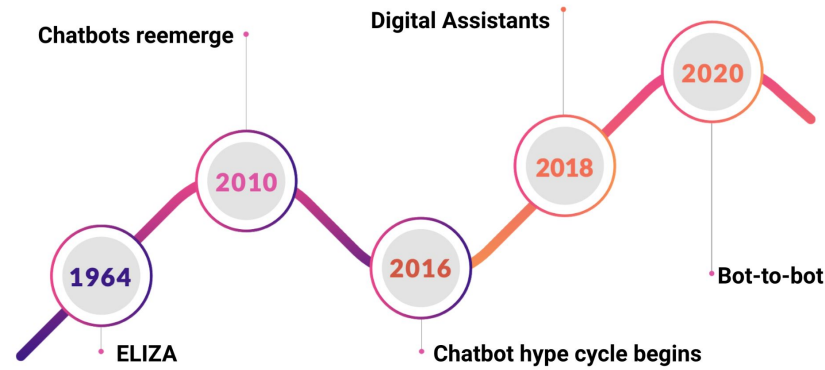
```
EEEEEE LL      IIII ZZZZZZZZ  AAAAA
EE      LL      II       ZZ  AA  AA
EEEEEE LL      II       ZZZ  AAAAAA
EE      LL      II       ZZ  AA  AA
EEEEEE LLLLLL IIII ZZZZZZZZ AA  AA
```

Eliza is a mock Rogerian psychotherapist.  
The original program was described by Joseph Weizenbaum in 1966.  
This implementation by Norbert Landsteiner 2005.

```
ELIZA: Please tell me what's been bothering you.
YOU:   I don't really know
ELIZA: Do you wish to be able to really know ?
YOU:   Hmm.. well, I guess yes
ELIZA: Do you say you guess yes for some special reason ?
YOU:   I don't really know
ELIZA: Does that trouble you ?
YOU:   What do you think?
ELIZA: What are your feelings now ?
YOU:   Sad
ELIZA: Does talking about this bother you ?
YOU:   █
```

Se basaba en encontrar las palabras claves del texto y utilizarlas para formular una pregunta

# Los chatbots y asistentes virtuales...



IBM Watson  
2006




Apple Siri  
2010



Google Now  
2012




Amazon  
alexa  
2015




Microsoft  
Cortana  
2015

# Los modelos que transformaron NLP



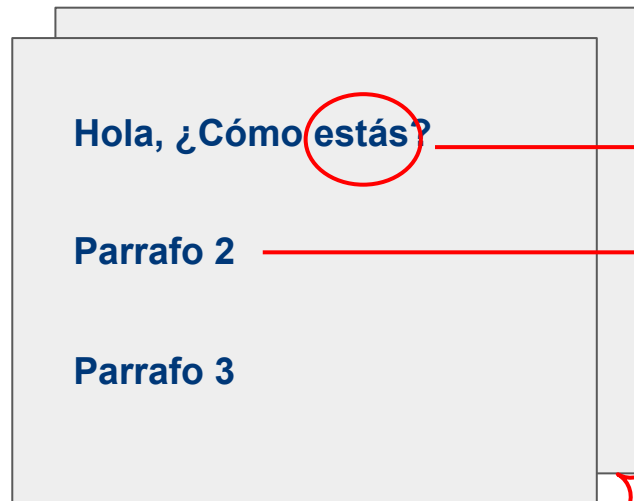
# Elegir la herramienta que más se ajusta a sus problemas



# Vectorización de texto



[LINK GLOSARIO](#)



Término  $t$ : palabra/símbolo "t" del documento

Document: su largo es variable, normalmente una sentencia/oración/párrafo.

Corpus: conjunto de documentos, forman todo el vocabulario.

No podemos ingresar texto  
a una red  
¿Cómo transformamos  
palabras a números?

vectorización

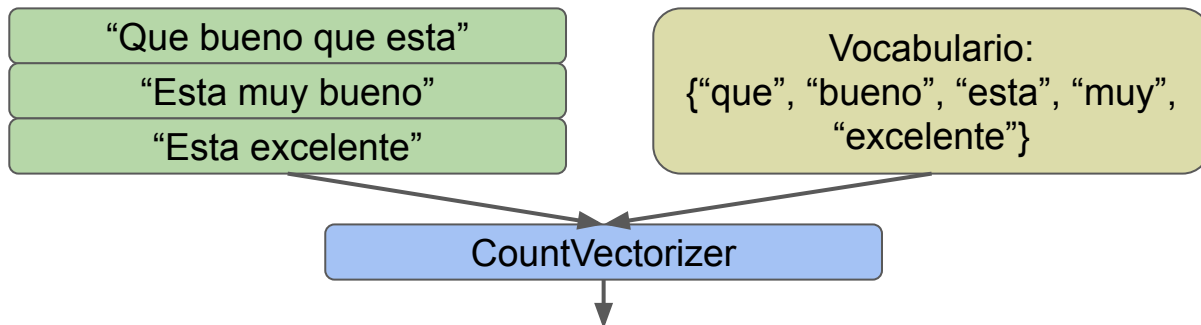


word2vect

# Vectores de frecuencia



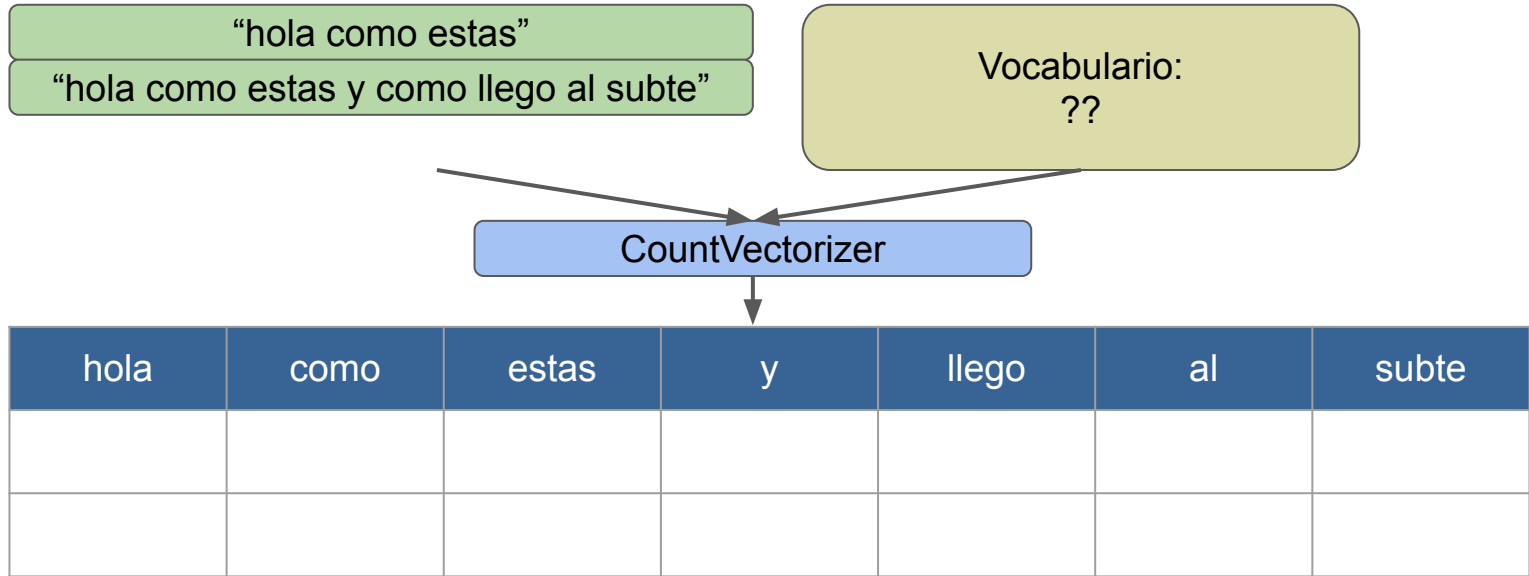
*"Por cada documento en el corpus se calcula un vector que representa cuántas veces cada palabra del vocabulario aparece en ese documento"*




que	bueno	esta	muy	excelente
2	1	1	0	0
0	1	1	1	0
0	0	1	0	1



# Vectores de frecuencia (ejemplo)



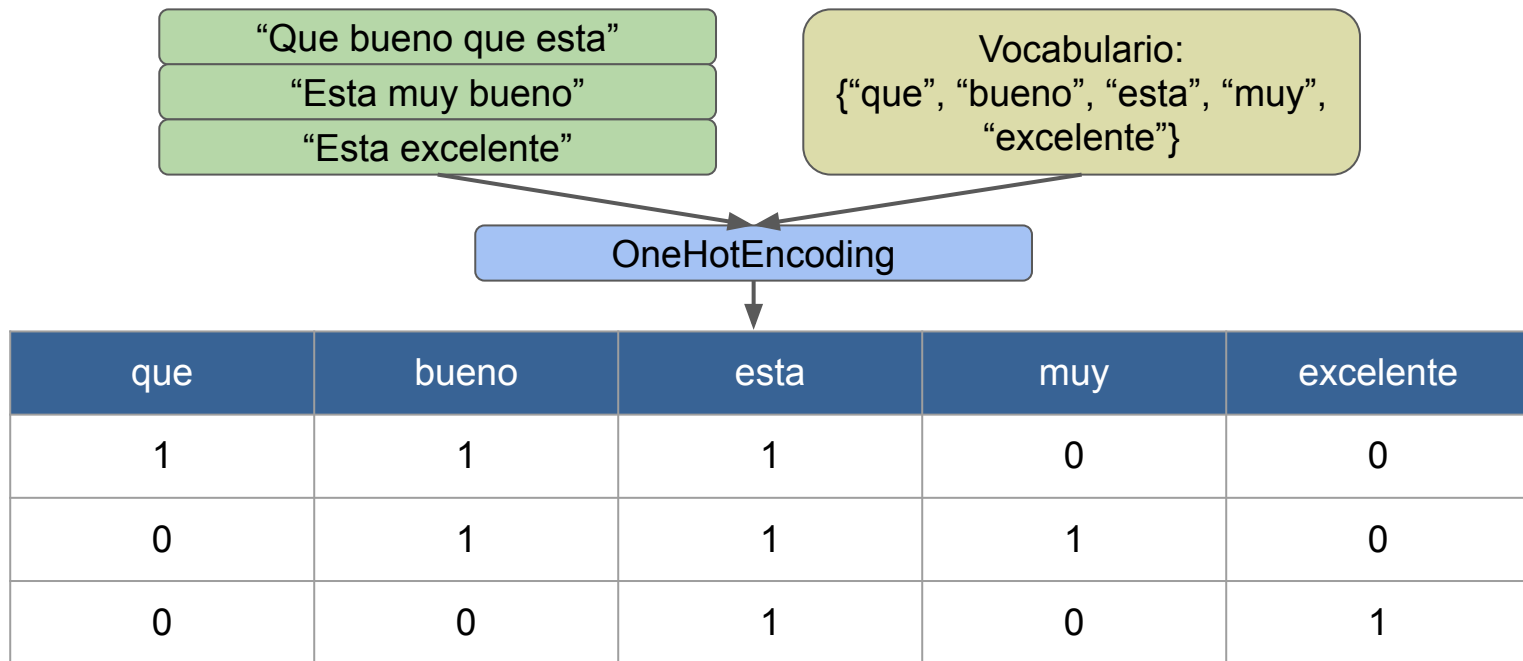
# Vectores de frecuencia (ejemplo resuelto)




# One-hot encoding



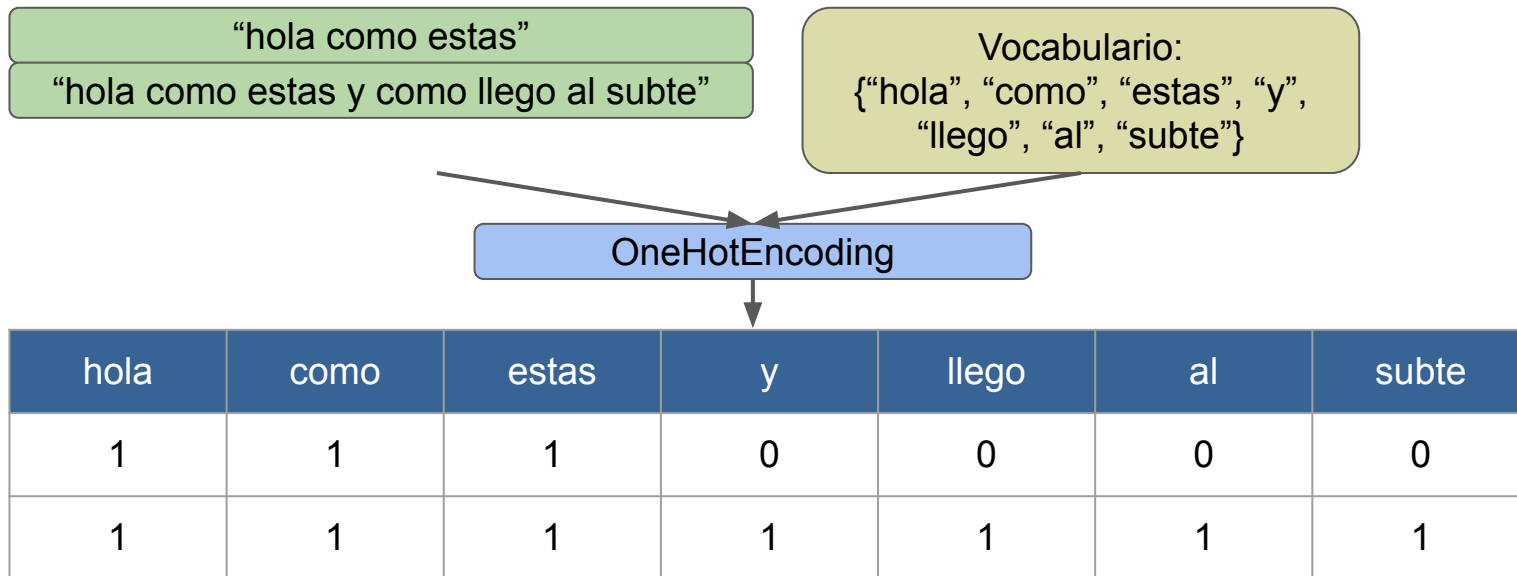
*"Por cada documento en el corpus se calcula un vector que representa si cada palabra del vocabulario aparece o no en ese documento"*



# One-hot encoding (ejemplo)



# One-hot encoding (ejemplo resuelto)



Los vectores tienen el largo del vocabulario

# One-hot encoding



## One-Hot Encoding

The quick brown fox jumped over the brown dog




time	cat	the	quick	brown	fox	jumped	over	dog	bird	flew	...	kangaroo	house
	0	1	0	0	0	0	0	0	0	0	...	0	0
	0	0	1	0	0	0	0	0	0	0	...	0	0
	0	0	0	1	0	0	0	0	0	0	...	0	0
	0	0	0	0	1	0	0	0	0	0	...	0	0
	0	0	0	0	0	1	0	0	0	0	...	0	0
	0	0	0	0	0	0	1	0	0	0	...	0	0
	0	1	0	0	0	0	0	0	0	0	...	0	0
	0	0	0	1	0	0	0	0	0	0	...	0	0
	0	0	0	0	0	0	0	1	0	0	...	0	0
Dictionary Size													

¡El idioma inglés tiene  
más de 180.000 palabras  
en su vocabulario en uso!



# Bolsa de palabras "Bag of words" (BOW)



Representar a las palabras por su presencia o ausencia en el texto (y a veces la cantidad). Previo a la existencia de los embeddings y no tiene en consideración el contexto.

El problema es que los vectores de frecuencia o One-Hot encoding son muy “sparse”

*“Necesito mucho espacio para guardar información que no aporta valor”*

# TF-IDF (Term frequency-Inverse term frequency)



*"Se utiliza como indicador de cuán importante es una palabra (término) en un documento"*

$$\text{TF-IDF}_{(n,d)} = \text{TF}_{(n,d)} \times \text{IDF}_{(n)}$$

Peso de un término (n) en un documento (d)

Frecuencia de aparición de un término (n) en un documento (d)

Factor IDF de un término (n)

El motor tan utilizado “Elasticsearch” se basa en este mecanismo



# Factor IDF (Inverse Document Frequency)



*"Proporción de documentos en el corpus que poseen el término"*

También suele utilizarse el logaritmo en base 2, su función es conseguir un coeficiente bajo, fácil de manejar


$$IDF_{(n)} = \log_{10} \frac{N}{DF_{(n)}}$$

N es el número total de documentos de la colección.

DF (Document Frequency) es el número documentos en los que aparece el término (n) a lo largo de toda la colección

Si el término aparece en todos los documentos el IDF será cero (es popular y por lo tanto aporta poco valor)

# Factor IDF



que	bueno	esta	muy	excelente
$\log(3/1)$	$\log(3/2)$	$\log(3/3)$	$\log(3/1)$	$\log(3/1)$
0.477	0.176	0	0.477	0.477

Se obtiene como la división de la cantidad de documentos sobre la suma en axis=0 (vertical) del OneHotEncoding.

# Factor TF (Term frequency)



*"Frecuencia de aparición de un término a lo largo de un documento"*

$$tf(n) = \sum_{D1} (n)$$

La frecuencia de aparición de un término (n) en un documento (D1) es la suma de las ocurrencias de dicho término

Se obtiene igual que el vector de frecuencia

# Factor TF-IDF



“Que bueno que esta”

“Esta muy bueno”

“Esta excelente”

Vocabulario:  
{“que”, “bueno”, “esta”, “muy”,  
“excelente”}

IDF

que	bueno	esta	muy	excelente
$\log(3/1)$	$\log(3/2)$	$\log(3/3)$	$\log(3/1)$	$\log(3/1)$

TF-IDF

que	bueno	esta	muy	excelente
$2 * \log(3/1)$	$1 * \log(3/2)$	$1 * \log(3/3)$	$0 * \log(3/1)$	$0 * \log(3/1)$
$0 * \log(3/1)$	$1 * \log(3/2)$	$1 * \log(3/3)$	$1 * \log(3/1)$	$0 * \log(3/1)$
$0 * \log(3/1)$	$0 * \log(3/2)$	$1 * \log(3/3)$	$0 * \log(3/1)$	$1 * \log(3/1)$

# TF-IDF (ejemplo)



“hola como estas”

“hola como estas y como llego al subte”

Vocabulario:  
??

TF

hola	como	estas	y	llego	al	subte

IDF

hola	como	estas	y	llego	al	subte

TF-IDF

hola	como	estas	y	llego	al	subte



# TF-IDF (ejemplo resuelto)

“hola como estas”

“hola como estas y como llego al subte”

Vocabulario:  
{“que”, “bueno”, “esta”, “muy”,  
“excelente”}

TF

hola	como	estas	y	llego	al	subte
1	1	1	0	0	0	0
1	2	1	1	1	1	1

IDF

hola	como	estas	y	llego	al	subte
$\log(2/2)$	$\log(2/2)$	$\log(2/2)$	$\log(2/1)$	$\log(2/1)$	$\log(2/1)$	$\log(2/1)$

TF-IDF

hola	como	estas	y	llego	al	subte
0	0	0	0	0	0	0
0	0	0	$\log(2/1)$	$\log(2/1)$	$\log(2/1)$	$\log(2/1)$

# Similitud coseno



*"Se utiliza para evaluar la dirección de dos vectores"*

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

Similitud coseno = 1 → los vectores tienen la misma dirección.

Similitud coseno = 0 → los vectores son ortogonales.

Similitud coseno = -1 → los vectores apuntan en sentido contrario.




Link al Colab



*LINK*





```
# Crear un modelo secuencial
model = Sequential()

# Crear la capa de entrada y la capa oculta (hidden):
# --> tantas entradas (input_shape) como columnas de entrada
# --> tantas neuronas (units) como deseemos
# --> utilizamos "sigmoid" como capa de activación
model.add(Dense(units=3, activation='relu', input_shape=(2,)))

# Crear la output, tendrá tantas neuronas como salidas deseadas
model.add(Dense(units=1, activation='sigmoid'))
```



Link al Colab



[LINK](#)



Link al Colab



[LINK](#)



# ¡Muchas gracias!